

Centro de Estudos das Cidades

Atualização Base de Dados de Alvarás

Henrique Guizzardi

24/10/2025

Dados

Os dados de alvarás são disponibilizados pelo Portal de Monitoramento e Avaliação da Implementação do Plano Diretor Estratégico da Prefeitura de São Paulo, na seção *Dados Abertos*, sob o título *Município de São Paulo: Alvarás de edificação nova (SISACOE e Aprova Digital)*. O download é fornecido em um arquivo .zip, nomeado no padrão *YYYYMMDD_msp_alvaras_sisacoe_aprova digital*, onde os oito primeiros dígitos indicam a data. Dentro do .zip estão dois arquivos com o mesmo conteúdo: um .csv e um .xlsx.

Tanto o arquivo .csv quanto o .xlsx possuem 31 variáveis, a saber:

- **origem** (*character*): sistema de origem do documento emitido (Aprova Digital ou SISACOE).
- **processo** (*character*): número do processo administrativo
- **unid_aprov** (*character*): unidade administrativa da Prefeitura responsável pela emissão do documento. Disponível apenas para registros do SISACOE.
- **n_documento** (*character*): número do documento emitido
- **assunto** (*character*): assunto do documento conforme consta no sistema de origem. Corresponde ao tipo do documento solicitado no momento do protocolo
- **aditivo_pd** (*character*): classificação para diferenciação dos documentos "iniciais" dos documentos "aditivos" (referentes a alvarás já emitidos anteriormente, tais como projeto modificativo e apostilamento), de modo a possibilitar a análise de dados provenientes dos dois sistemas de forma integrada
- **assunto_pd** (*character*): classificação em assuntos padronizados, de modo a possibilitar a análise de dados provenientes dos dois sistemas de forma integrada
- **data_autuacao** (*character*): data de autuação
- **ano_autuacao** (*integer*): ano de autuação

- `data_emissao` (*character*): data de emissão do documento
- `ano_emissao` (*integer*): ano de emissão do documento
- `sql` (*character*): número do cadastro fiscal do imóvel, composto de códigos de Setor, Quadra e Lote
- `endereco` (*character*): endereço do imóvel
- `zona_uso` (*character*): zona de uso referente ao licenciamento
- `uso` (*character*): classificação em "residencial", "não residencial" ou "misto", a partir da lista de valores constantes na coluna "Subcategoria de uso"
- `uso_subcat` (*character*): subcategoria(s) de uso e grupos de atividades licenciados.
- `area_terreno` (*character*): área do terreno
- `ac_total` (*character*): área construída total licenciada
- `blocos` (*integer*): quantidade de blocos
- `pavimentos` (*integer*): quantidade de pavimentos
- `unid_resid` (*integer*): quantidade de unidades residenciais
- `unid_his` (*integer*): quantidade de unidades de Habitação de Interesse Social. Disponível apenas para registros do Aprova Digital.
- `unid_hmp` (*integer*): quantidade de unidades de Habitação de Mercado Popular. Disponível apenas para registros do Aprova Digital
- `unid_r2h_r2v` (*integer*): quantidade de unidades residenciais tipo R2H ou R2V. Disponível apenas para registros do Aprova Digital.
- `ativid_nr` (*character*): atividades não residenciais licenciadas. Disponível apenas para registros do Aprova Digital
- `coord_x` (*character*): coordenada x do ponto correspondente à localização estimada do imóvel, no sistema de referência de coordenadas SIRGAS 2000 (EPSG 31983). O georreferenciamento foi realizado a partir do SQL, através da correspondência com bases vetoriais de lotes e quadras do cadastro fiscal
- `coord_y` (*character*): coordenada y do ponto correspondente à localização estimada do imóvel, no sistema de referência de coordenadas SIRGAS 2000 (EPSG 31983). O georreferenciamento foi realizado a partir do SQL, através da correspondência com bases vetoriais de lotes e quadras do cadastro fiscal
- `distrito` (*character*): nome do distrito em que está localizado o imóvel. Obtido a partir do cruzamento com a base vetorial de distritos.
- `subprefeitura` (*character*): nome da subprefeitura em que está localizado o imóvel. Obtido a partir do cruzamento com a base vetorial de distritos

- **georref_nivel** (*character*): indica se o georreferenciamento foi realizado em nível de lote ou em nível de quadra. Nos casos em que não está especificado o nível do georreferenciamento, trata-se de alvarás que não foram georreferenciados, por não terem SQL ou por não ter sido encontrada correspondência com as bases vetoriais do cadastro fiscal utilizadas
- **georref_modo** (*character*): o georreferenciamento foi realizado para a maior parte dos registros em nível de lote, através de correspondência do SQL com bases vetoriais de lotes. Quando necessário, foram utilizadas informações da filiação do SQL

Estrutura dos scripts

1. 1_alvaras_trusted.R

- **Input:** `mzp_alvaras_sisacoe_aprova digital.csv`
- **Descrição:** Importa dados brutos diretamente do portal e faz pré-processamento. O pré-processamento possui as seguintes etapas: checa atributos, limpando dados em texto e padronizando datas; ajusta variáveis numéricas, como áreas da construção e terreno, blocos, andares, unidades, etc.; ajusta variáveis categóricas, como categoria de uso, endereços, etc.
- **Output:** `alvaras_pde.parquet`

2. 2_alvaras_geoloc.R

- **Input:** `alvaras_pde.parquet` e `SubprefectureMSP_SIRGAS.shp` (shapefile das sub-prefeituras de São Paulo)
- **Descrição:** Faz georreferenciamento em duas etapas: primeiro, por meio das coordenadas fornecidas diretamente da base; segundo, pelo API ArcGis, utilizando o endereço tratado para as observações que não possuem as coordenadas X e Y nos dados
- **Output:** `geo_alvaras_pde.parquet`

3. 3_alvaras_empresendimentos_pde.R

- **Input:** `geo_alvaras_pde.parquet`
- **Descrição:** agrupa os alvarás em empreendimentos por meio de um algoritmo baseado em três critérios: (i) igualdade ou inclusão do SQL, (ii) igualdade da área do terreno e (iii) distância entre os pontos inferior a 100 metros. A partir deles, são definidos três tipos de correspondência: perfeita (os três critérios atendidos), parcial (dois critérios atendidos) e única (apenas um critério atendido). Nos casos parciais, realizamos verificações adicionais, como comparação entre área construída e número de unidades, para tentar promover o match a perfeito. Em seguida, atribuímos os IDs de empreendimento, priorizando matches perfeitos, depois parciais, únicos e, por fim, observações sem correspondência. Por último, agregamos as informações por empreendimento, tratando separadamente atributos em situações de parcelamento. Mantemos apenas os empreendimentos que possuem alvarás de aprovação e execução e que apresentam número de unidades igual a NA ou menor do que cinco
- **Atenção:** demanda uma alta quantidade de memória para rodar. Costumo rodar no POOL N2 da máquina virtual.
- **Output:** `geo_alvaras_emp_pde.parquet`

Base final

A partir do processo efetuado pelos scripts descritos acima, geramos uma base de dados de empreendimentos licenciados em São Paulo a partir de 2010. A base final possui 48 variáveis, a saber:

- `id_empreendimento_num` (*integer*): ID do empreendimento
- `tipo_match` (*character*): categoria de match do empreendimento. Podem ser os seguintes:
 - “perfeito”
 - “parcial_1” (SQL e área)
 - “parcial_2” (SQL e distância)
 - “parcial_3” (área e distância)
 - “único” (apenas SQL)
 - “sem match”
- `ano_aprovacao` (*double*): ano de emissão do alvará de aprovação mais atual
- `ano_execucao` (*double*): ano de emissão do alvará de execução mais atual
- `n_alvaras` (*integer*): número de alvarás emitidos pelo empreendimento
- `n_alvaras_aprovacao` (*integer*): número de alvarás de aprovação emitidos pelo empreendimento
- `n_alvaras_execucao` (*integer*): número de alvarás de execução emitidos pelo empreendimento
- `data_autuacao_projeto` (*date*): data de autuação do projeto, ou seja, data de autuação do alvará de aprovação mais atual
- `data_validacao_projeto` (*date*): data de validação do projeto, ou seja, data de emissão do alvará de aprovação mais atual
- `data_autuacao_execucao` (*date*): data de autuação da execução, ou seja, data de autuação do alvará de execução mais atual
- `data_validacao_execucao` (*date*): data de validação da execução, ou seja, data de emissão do alvará de execução mais atual
- `diff_dias_projeto` (*double*): número de dias entre as datas de autuação e validação do projeto
- `diff_dias_execucao` (*double*): número de dias entre as datas de autuação e validação da execução
- `unidade_pmsp` (*character*): lista das unidades administrativas da Prefeitura responsáveis pela emissão dos alvarás

- `categoria_de_uso_grupo` (*character*): classifica em *ERP* os empreendimentos que apresentarem ou `ind_his` igual a TRUE, ou `ind_hmp` igual a TRUE, ou `ind_ezeis` igual a TRUE; classifica em *ERM*, entre os que sobraem, se a variável `categoria_de_uso` apresentar algum dos seguintes strings: R2V|R202|R302|R2H|R301|R302|R303|(?<!N)R1|(?<!N)R2; por fim, categoriza em *Outro* o que restar
- `categoria_de_uso_lista` (*character*): lista dos valores em `categoria_de_uso`
- `area_do_terreno` (*double*): valor da área do terreno no alvará mais atual, omitindo NAs
- `area_da_construcao` (*double*): valor da área da construção no alvará mais atual, omitindo NAs
- `n_blocos` (*double*): valor do número de blocos no alvará mais atual, omitindo NAs
- `n_pavimentos` (*double*): valor do número de pavimentos no alvará mais atual, omitindo NAs
- `n_unidades` (*double*): valor do número de unidades no alvará mais atual, omitindo NAs
- `n_pavimentos_por_bloco` (*double*): divisão do número de pavimentos pelo número de blocos
- `n_unidades_por_bloco` (*double*): divisão do número de unidades pelo número de blocos
- `n_unidades_his` (*double*): valor de unidades HIS no alvará mais atual, omitindo NAs
- `n_unidades_his_por_bloco` (*double*): divisão do número de unidades HIS pelo número de blocos
- `n_unidades_hmp` (*double*): valor de unidades HMP no alvará mais atual, omitindo NAs
- `n_unidades_hmp_por_bloco` (*double*): divisão do número de unidades HMP pelo número de blocos
- `n_unidades_r2h_r2v` (*double*): valor de unidades R2h/R2v no alvará mais atual, omitindo NAs
- `n_unidades_r2h_r2v_por_bloco` (*double*): divisão do número de unidades R2h/R2v pelo número de blocos
- `sql_incra_lista` (*character*): códigos SQL de todos os alvarás do empreendimento
- `sql_incra` (*character*): código SQL do alvará mais atual
- `n_enderecos` (*integer*): número de endereços distintos entre os alvarás
- `endereco` (*character*): endereço do alvará mais atual, excluindo NAs
- `endereco_lista` (*character*): lista de endereços distintos entre os alvarás
- `distrito` (*character*): distrito do alvará mais atual, excluindo NAs
- `subprefeitura` (*character*): subprefeitura do alvará mais atual, excluindo NAs
- `zona_de_uso_registro` (*character*): lista de zonas de uso entre os alvarás

- `ind_edificacao_nova` (*logical*): igual a TRUE se houver algum `ind_edificacao_nova` igual a TRUE
- `ind_aprovacao` (*logical*): igual a TRUE se houver algum `ind_aprovacao` igual a TRUE
- `ind_execucao` (*logical*): igual a TRUE se houver algum `ind_execucao` igual a TRUE
- `ind_r2h` (*logical*): igual a TRUE se houver algum `ind_r2h` igual a TRUE
- `ind_r2v` (*logical*): igual a TRUE se houver algum `ind_r2v` igual a TRUE
- `ind_his` (*logical*): igual a TRUE se houver algum `ind_his` igual a TRUE
- `ind_hmp` (*logical*): igual a TRUE se houver algum `ind_hmp` igual a TRUE
- `ind_ezeis` (*logical*): igual a TRUE se houver algum `ind_ezeis` igual a TRUE
- `ind_uso_misto` (*logical*): igual a TRUE se `categoria_de_uso_grupo` for diferente de *Outra*, `ind_edificacao_nova` for igual a TRUE e se `categoria_de_uso_lista` possuir algum dos seguintes strings: NR|C1|C2|C3|S1|S2|S3|E1|E2|E3|E4
- `ind_zeis` (*logical*): igual a TRUE se `zona_de_uso_registro` possuir a string "ZEIS"
- `ind_parcelamento` (*logical*): igual a TRUE se houver algum `ind_parcelamento` igual a TRUE
- `geometry` (*POINT [m]*): coordenadas espaciais do empreendimento